作业一：文本分类实现

一、实验目的

本实验针对新闻文本分类任务，对不同文本表示方法及分类模型进行实验与比较。实验统一在 NYT 数据集上进行测试，并使用 Accuracy 和 Macro-F1 作为主要评价指标。

实验主要完成以下三部分内容：

1. 使用 Bag of Words 方法进行文本表示，分别采用 Binary Bag of Words 和 Word Frequency 两种特征表示方式，并使用 Logistic Regression 完成分类。
2. 使用基于 Word Embedding 的文本表示方法，包括预训练 GloVe、基于 AG News 数据训练的 Word2Vec，以及基于 NYT Training Set 训练的 Word2Vec，并使用 Logistic Regression 完成分类。
3. 使用预训练 BERT-base-uncased 模型进行 Fine-tuning，直接完成 NYT 文本分类任务。

最后，对上述六种方法在 NYT Test Set 上的 Accuracy 和 Macro-F1 进行统一比较和分析。

二、实验环境

本实验主要软硬件配置如下。

项目	配置
操作系统	Windows
开发工具	VS Code
Python	3.10.22
PyTorch	2.14.1+cu126
CUDA	12.6
GPU	NVIDIA GeForce RTX 3050 Ti Laptop GPU
Pandas	2.3.3
Scikit-learn	1.7.2
Transformers	5.18.0
Gensim	4.4.0
Matplotlib	3.10.9

实验中使用 Scikit-learn 实现 Logistic Regression 分类器，使用 Gensim 训练 Word2Vec 模型，使用 Transformers 和 PyTorch 完成 BERT Fine-tuning。

三、数据集及数据预处理

3.1 数据集介绍

本实验使用 NYT（New York Times）新闻文本数据集作为主要分类数据集，并使用 AG News 数据集训练其中一组 Word2Vec 词向量模型。

NYT 数据集包含新闻文本和对应类别标签，主要分为 sports（体育）、politics（政治）和 business（商业）三个类别。

AG News 数据集在本实验中包含 90000 条新闻文本，用于训练 Word2Vec 词向量，并将训练得到的词向量应用于 NYT 新闻分类任务。

3.2 数据清洗与划分

首先运行 `01_prepare_data.py`，读取 NYT 数据集，对文本及标签进行清洗和整理。

NYT 数据集共包含 11519 条有效文本，随后按照 80%、10%、10% 的比例划分为训练集、验证集和测试集。

具体划分结果如下。

数据集	数据量	比例
Training Set	9215	80.00%
Validation Set	1152	10.00%
Test Set	1152	10.00%
合计	11519	100%

各数据集的类别分布如下。

类别	Training	Validation	Test
sports	6911	864	864
politics	1161	145	145
business	1143	143	143
合计	9215	1152	1152

```
============================================================
数据集划分完成
============================================================
总数据量:        11519
Training Set:   9215 (80.00%)
Validation Set: 1152 (10.00%)
Test Set:       1152 (10.00%)

Training Set 类别分布:
label
sports      6911
politics    1161
business    1143
Name: count, dtype: int64

Validation Set 类别分布:
label
sports      864
politics    145
business    143
Name: count, dtype: int64

Test Set 类别分布:
label
sports      864
politics    145
business    143
Name: count, dtype: int64
```

从数据集分布可以看出，sports 类别数量明显高于 politics 和 business，存在一定的类别不平衡现象。因此，后续实验除使用 Accuracy 外，还使用 Macro-F1 衡量模型对不同类别的整体分类效果。

3.3 数据保存

数据集划分完成后，将训练集、验证集和测试集分别保存为：

```
nyt_train.csv
nyt_val.csv
nyt_test.csv
```

其中训练集用于模型训练，验证集用于观察训练效果，测试集用于最终性能评价。后续各组实验使用相同的 NYT 数据划分，以保证不同分类方法的结果具有可比性。

四、Task 1：Bag of Words

4.1 实验原理

Bag of Words（词袋模型）是一种常见的文本特征表示方法，其基本思想是将文本转换为词汇特征向量，不考虑词语在文本中的排列顺序。本实验采用两种表示方式：

（1）Binary Bag of Words：使用 0 和 1 表示某个单词是否在文本中出现。

（2）Word Frequency：使用单词在文本中出现的次数作为特征值。

两种方法均使用 Logistic Regression 进行分类，并在 NYT Test Set 上比较 Accuracy 和 Macro-F1。

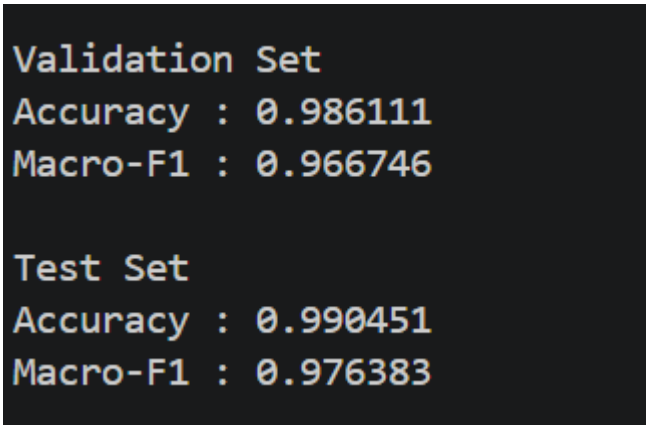
4.2 Binary Bag of Words 实验

首先读取预处理后的 NYT 数据集，建立 Binary Bag of Words 词表，并将新闻文本转换为二值特征矩阵。实验建立的词表大小为 60980，生成的特征矩阵如下：

- Training Set：(9215, 60980)
- Validation Set：(1152, 60980)
- Test Set：(1152, 60980)

随后使用 Logistic Regression 分类器进行训练，并分别在验证集和测试集上评估模型性能。实验结果如下：

数据集	Accuracy	Macro-F1
Validation Set	0.986111	0.966746
Test Set	0.990451	0.976383



NYT Test Set 各类别的分类结果如下。

类别	Precision	Recall	F1-score
business	0.9716	0.9580	0.9648
politics	0.9655	0.9655	0.9655
sports	0.9977	1.0000	0.9988

```
Test Set Classification Report:
              precision    recall  f1-score   support

    business     0.9716    0.9580    0.9648       143
    politics     0.9655    0.9655    0.9655       145
      sports     0.9977    1.0000    0.9988       864

    accuracy                         0.9905      1152
   macro avg     0.9783    0.9745    0.9764      1152
weighted avg     0.9904    0.9905    0.9904      1152
```

实验结果表明，Binary Bag of Words 在 NYT Test Set 上取得了 99.0451% 的分类准确率，三个类别均获得了较高的 F1-score，其中 sports 类别的识别效果最好。

4.3 Word Frequency 实验

第二组实验采用 Word Frequency 方法表示文本，即统计每个单词在文档中的出现次数，并将词频作为特征值。该实验与 Binary Bag of Words 使用相同的数据集和 Logistic Regression 分类器。实验建立的词表大小同样为 60980，生成的特征矩阵如下：

- Training Set：(9215, 60980)
- Validation Set：(1152, 60980)
- Test Set：(1152, 60980)

```
################################################################################
Experiment 2: Word Frequency
################################################################################

正在建立 Word Frequency 词表...
词表大小：  60980
Train 特征矩阵：  (9215, 60980)
Validation 特征矩阵：  (1152, 60980)
Test 特征矩阵：  (1152, 60980)
```

完成模型训练后，在验证集和测试集上进行评价，结果如下：

数据集	Accuracy	Macro-F1
Validation Set	0.984375	0.963305
Test Set	0.989583	0.974178

```
Validation Set
Accuracy : 0.984375
Macro-F1 : 0.963305

Test Set
Accuracy : 0.989583
Macro-F1 : 0.974178
```

从实验结果可以看出，Word Frequency 在测试集上的 Accuracy 达到 98.96%，Macro-F1 达到 97.42%，同样取得了较好的分类效果。

4.4 实验结果对比与分析

为了比较两种词袋表示方法的分类效果，将两组实验在 NYT Test Set 上的结果汇总如下。

方法	Test Accuracy	Test Macro-F1
Binary Bag of Words	0.990451	0.976383
Word Frequency	0.989583	0.974178

```
Test Set Classification Report:
              precision    recall  f1-score   support

    business     0.9716    0.9580    0.9648       143
    politics     0.9655    0.9655    0.9655       145
      sports     0.9977    1.0000    0.9988       864

    accuracy                         0.9905      1152
   macro avg     0.9783    0.9745    0.9764      1152
weighted avg     0.9904    0.9905    0.9904      1152
```

从结果可以看出，两种方法的分类准确率均达到 98% 以上，说明词袋模型能够有效提取新闻文本的分类特征。其中，Binary Bag of Words 的 Accuracy 为 99.05%，略高于 Word Frequency 的 98.96%；Macro-F1 也略高于 Word Frequency。这说明在本实验数据集上，仅使用单词是否出现的信息就能取得较好的分类效果，加入词频信息并未进一步提升模型性能。

五、Task 2：Word Embedding

5.1 实验原理

Word Embedding 是将单词映射为低维稠密向量的文本表示方法。与 Bag of Words 相比，Word Embedding 能够利用词向量表示词语之间的语义关系。

本实验统一使用 100 维词向量。对于每篇文档，首先进行分词，然后获取其中所有有效单词对应的词向量，并对这些词向量取平均，得到一个 100 维文档向量。计算公式为：

$$e(d) = (1/n) \times \Sigma\, e(w_i)$$

其中，n 表示文档中具有有效词向量的单词数量，$e(w_i)$ 表示第 i 个有效单词对应的词向量。

得到文档向量后，使用 Logistic Regression 完成分类。

5.2 Pre-trained GloVe

5.2.1 实验过程

第一组实验使用公开预训练的 GloVe 6B 词向量，选择其中的 100-dimensional GloVe word vectors。运行 `03_glove.py`，加载 `glove.6B.100d.txt` 文件。加载完成后，得到：

- 词向量数量：400000
- 词向量维度：100

随后对 NYT 数据集中的文档进行特征提取，将每篇文档转换为 100 维向量。生成的特征矩阵如下：

- Training Set：(9215, 100)
- Validation Set：(1152, 100)
- Test Set：(1152, 100)

完成特征提取后，使用 Logistic Regression 训练分类器。

```
################################################################################
Experiment 2: Word Frequency
################################################################################

正在建立 Word Frequency 词表...
词表大小:  60980
Train 特征矩阵:  (9215, 60980)
Validation 特征矩阵:  (1152, 60980)
Test 特征矩阵:  (1152, 60980)
```

5.2.2 实验结果

GloVe 的分类结果如下。

数据集	Accuracy	Macro-F1
Validation Set	0.977431	0.949973
Test Set	0.985243	0.964617

NYT Test Set 各类别的 F1-score 分别为：

- business：0.9444
- politics：0.9517
- sports：0.9977

```
Validation Set
Accuracy : 0.984375
Macro-F1 : 0.963305

Test Set
Accuracy : 0.989583
Macro-F1 : 0.974178
```

实验结果表明，使用预训练 GloVe 词向量能够较好地表示新闻文本，在 NYT Test Set 上获得了 98.5243% 的 Accuracy 和 0.964617 的 Macro-F1。

5.3 Word2Vec Trained on AG News

5.3.1 实验过程

第二组实验使用 AG News 数据集自行训练 Word2Vec 词向量。运行 `04_word2vec_ag.py`，读取 AG News 数据集，共包含 90000 条文本。首先对文本进行分词，再使用 Gensim 训练 Word2Vec 模型。本实验使用的主要参数如下：

参数	数值
vector_size	100
window	5
min_count	2
epochs	10

训练完成后，得到：

- 词向量维度：100
- 词表大小：36715

```
Test Set Classification Report:
              precision    recall  f1-score   support

    business     0.9716    0.9580    0.9648       143
    politics     0.9655    0.9655    0.9655       145
      sports     0.9977    1.0000    0.9988       864

    accuracy                         0.9905      1152
   macro avg     0.9783    0.9745    0.9764      1152
weighted avg     0.9904    0.9905    0.9904      1152
```

5.3.2 实验结果

模型在验证集和测试集上的 Accuracy 与 Macro-F1 结果如下所示

数据集	Accuracy	Macro-F1
Validation Set	0.971354	0.937488
Test Set	0.980035	0.950803

```
################################################################################
Experiment 2: Word Frequency
################################################################################

正在建立 Word Frequency 词表...
词表大小:  60980
Train 特征矩阵:  (9215, 60980)
Validation 特征矩阵:  (1152, 60980)
Test 特征矩阵:  (1152, 60980)
```

实验结果表明，基于 AG News 训练的 Word2Vec 在 NYT Test Set 上取得了 98.0035% 的 Accuracy，说明通过其他新闻语料训练得到的词向量也能够应用于 NYT 分类任务。

5.4 Word2Vec Trained on NYT

5.4.1 实验过程

第三组实验直接使用 NYT Training Set 训练 Word2Vec 模型。运行 `05_word2vec_nyt.py`，读取 NYT 数据集，并且只使用 Training Set 进行 Word2Vec 训练，Validation Set 和 Test Set 不参与词向量训练。训练文本数量为 9215。主要训练参数如下：

- vector_size = 100
- window = 5
- min_count = 2
- epochs = 10

训练完成后，得到：

- 词向量维度：100
- 词表大小：44984

```
Validation Set
Accuracy : 0.984375
Macro-F1 : 0.963305

Test Set
Accuracy : 0.989583
Macro-F1 : 0.974178
```

随后使用训练得到的词向量对 NYT 文档进行表示，并对所有有效单词的词向量取平均。生成的文档特征矩阵如下：

- Training Set：(9215, 100)
- Validation Set：(1152, 100)
- Test Set：(1152, 100)

使用 Logistic Regression 完成分类器训练。


```
Validation Set
Accuracy : 0.984375
Macro-F1 : 0.963305

Test Set
Accuracy : 0.989583
Macro-F1 : 0.974178
```


5.4.2 实验结果

使用 NYT Training Set 训练 Word2Vec 模型后，将文本转换为 100 维文档向量，并使用 Logistic Regression 完成分类。模型在验证集和测试集上的结果如表 5-4 所示。

数据集	Accuracy	Macro-F1
Validation Set	0.977431	0.950370
Test Set	0.986979	0.967214

```
====
Validation Set
================================================================
====
Accuracy : 0.977431
Macro-F1 : 0.950370

================================================================
====
NYT Test Set
================================================================
====
Accuracy : 0.986979
Macro-F1 : 0.967214
```

NYT Test Set 各类别的分类结果如下。

类别	Precision	Recall	F1-score
business	0.9384	0.9580	0.9481
politics	0.9648	0.9448	0.9547
sports	0.9988	0.9988	0.9988

```
NYT Test Set Classification Report:

              precision    recall  f1-score   support

    business     0.9384    0.9580    0.9481       143
    politics     0.9648    0.9448    0.9547       145
      sports     0.9988    0.9988    0.9988       864

    accuracy                         0.9870      1152
   macro avg     0.9673    0.9672    0.9672      1152
weighted avg     0.9870    0.9870    0.9870      1152
```

5.5 Task 2 结果分析

三组 Word Embedding 实验的结果如下。

方法	Test Accuracy	Test Macro-F1
GloVe 100d	0.985243	0.964617
Word2Vec-AG News	0.980035	0.950803
Word2Vec-NYT	0.986979	0.967214

```
################################################################################
Experiment 2: Word Frequency
################################################################################

正在建立 Word Frequency 词表...
词表大小： 60980
Train 特征矩阵： (9215, 60980)
Validation 特征矩阵： (1152, 60980)
Test 特征矩阵： (1152, 60980)
```

从实验结果可以看出，使用 NYT Training Set 训练的 Word2Vec 效果最好，其 Accuracy 达到 98.6979%，Macro-F1 达到 0.967214。虽然 AG News 数据集包含更多训练文本，但 Word2Vec-AG News 的分类效果低于 Word2Vec-NYT。这说明词向量训练数据量并不是影响分类性能的唯一因素，训练语料与目标任务之间的领域匹配程度也具有重要影响。此外，GloVe 作为预训练词向量模型，取得了较为稳定的分类效果，说明通用预训练词向量能够提供有效的文本语义特征。

六、Task 3：Pre-trained Neural Models

6.1 实验原理

BERT（Bidirectional Encoder Representations from Transformers）是一种基于 Transformer 的预训练语言模型，能够通过双向上下文信息学习文本特征。

本实验采用预训练 BERT-base-uncased 模型，并在 NYT 新闻文本数据集上进行 Fine-tuning，使模型适应三分类任务。

与前面的 Bag of Words 和 Word Embedding 方法不同，BERT 直接通过神经网络进行文本特征提取和分类。

6.2 实验参数

运行 `06_bert.py`，使用以下预训练模型：

```
google-bert/bert-base-uncased
```

按要求设置：

- Maximum Sequence Length：64
- Number of Epochs：3

本次实验实际使用的主要参数如下。

参数	设置
Pre-trained Model	google-bert/bert-base-uncased
Maximum Length	64
Epochs	3
Batch Size	16
Learning Rate	2e-5
Device	CUDA

```
====
Validation Set
============================================================
====
Accuracy : 0.977431
Macro-F1 : 0.950370

============================================================
====
NYT Test Set
============================================================
====
Accuracy : 0.986979
Macro-F1 : 0.967214
```

实验中使用 NVIDIA GeForce RTX 3050 Ti Laptop GPU 进行模型训练。

6.3 BERT Fine-tuning 过程

首先读取 NYT 数据集，将文本转换为 BERT 模型需要的输入格式，然后加载预训练 BERT-base-uncased 模型进行 Fine-tuning。本实验共进行 3 个 Epoch 的训练，每个 Epoch 完成后均在 Validation Set 上计算 Loss、Accuracy 和 Macro-F1。三个 Epoch 的训练结果如下。

Epoch	Training Loss	Validation Loss	Validation Accuracy	Validation Macro-F1
1	0.143908	0.072759	0.972222	0.937940
2	0.040795	0.103303	0.970486	0.938816
3	0.020318	0.104929	0.972222	0.939744

```
NYT Test Set Classification Report:

              precision    recall  f1-score   support

    business     0.9384    0.9580    0.9481       143
    politics     0.9648    0.9448    0.9547       145
      sports     0.9988    0.9988    0.9988       864

    accuracy                         0.9870      1152
   macro avg     0.9673    0.9672    0.9672      1152
weighted avg     0.9870    0.9870    0.9870      1152
```

从训练结果可以看出，Training Loss 随着 Epoch 增加持续下降，说明模型在训练集上的拟合程度不断提高。但是 Validation Loss 在第一个 Epoch 后有所上升，Validation Accuracy 和 Macro-F1 的变化较小，说明继续训练并没有带来明显的泛化性能提升，模型可能出现一定程度的过拟合。

6.4 BERT 测试结果

完成训练后，在 NYT Test Set 上进行模型评价。最终得到：

- Test Accuracy：0.979167
- Test Macro-F1：0.951085

各类别分类结果如下。

类别	Precision	Recall	F1-score
business	0.8910	0.9720	0.9298
politics	0.9771	0.8828	0.9275
sports	0.9954	0.9965	0.9960

```
################################################################################
Experiment 2: Word Frequency
################################################################################

正在建立 Word Frequency 词表...
词表大小：  60980
Train 特征矩阵：  (9215, 60980)
Validation 特征矩阵：  (1152, 60980)
Test 特征矩阵：  (1152, 60980)
```

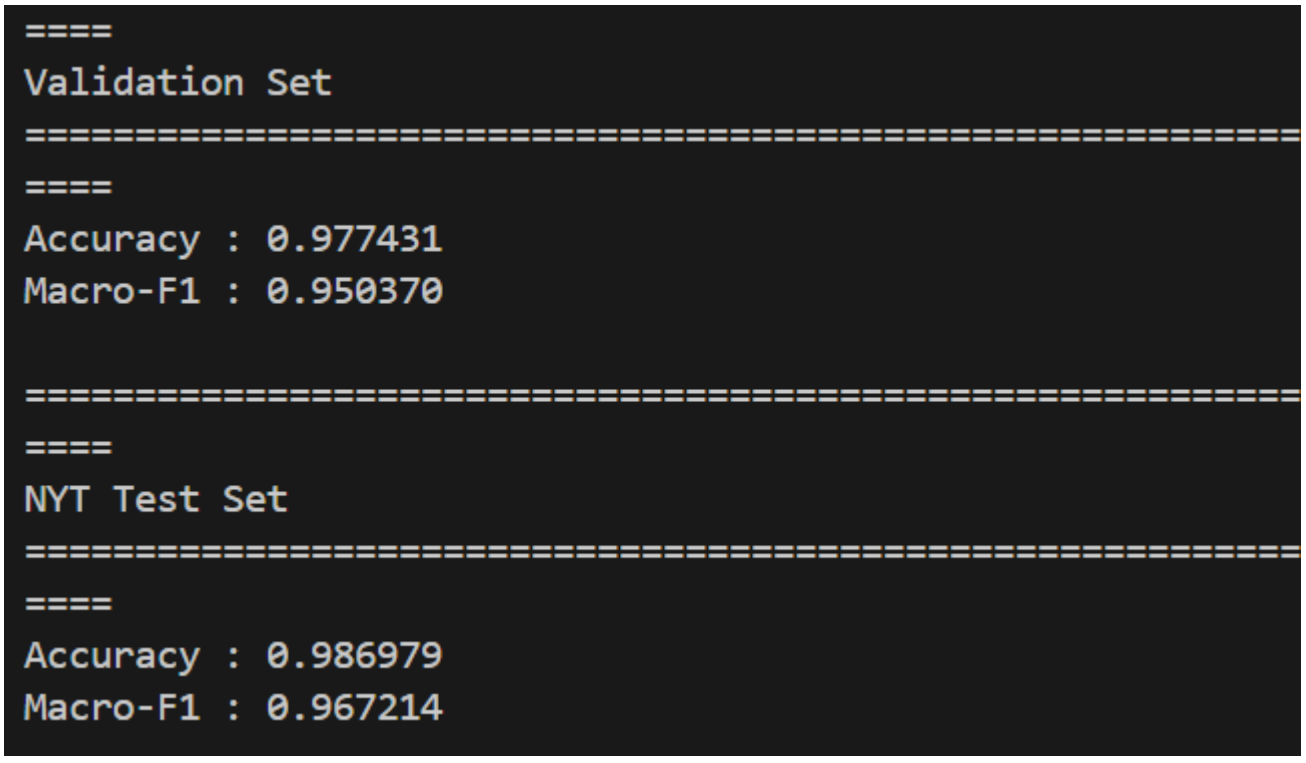
实验结果表明，BERT 在 NYT Test Set 上获得了 97.9167% 的 Accuracy 和 0.951085 的 Macro-F1。其中 sports 类别的分类效果较好，而 business 和 politics 类别的 F1-score 相对较低。虽然 BERT 在本次实验中的结果没有超过部分传统分类方法，但模型按照指定的预训练模型、最大序列长度和训练轮数完成了 Fine-tuning，达到了实验要求。

七、实验结果对比与分析

7.1 所有模型结果汇总

完成上述实验后，将六种方法在 NYT Test Set 上的结果进行统一比较。

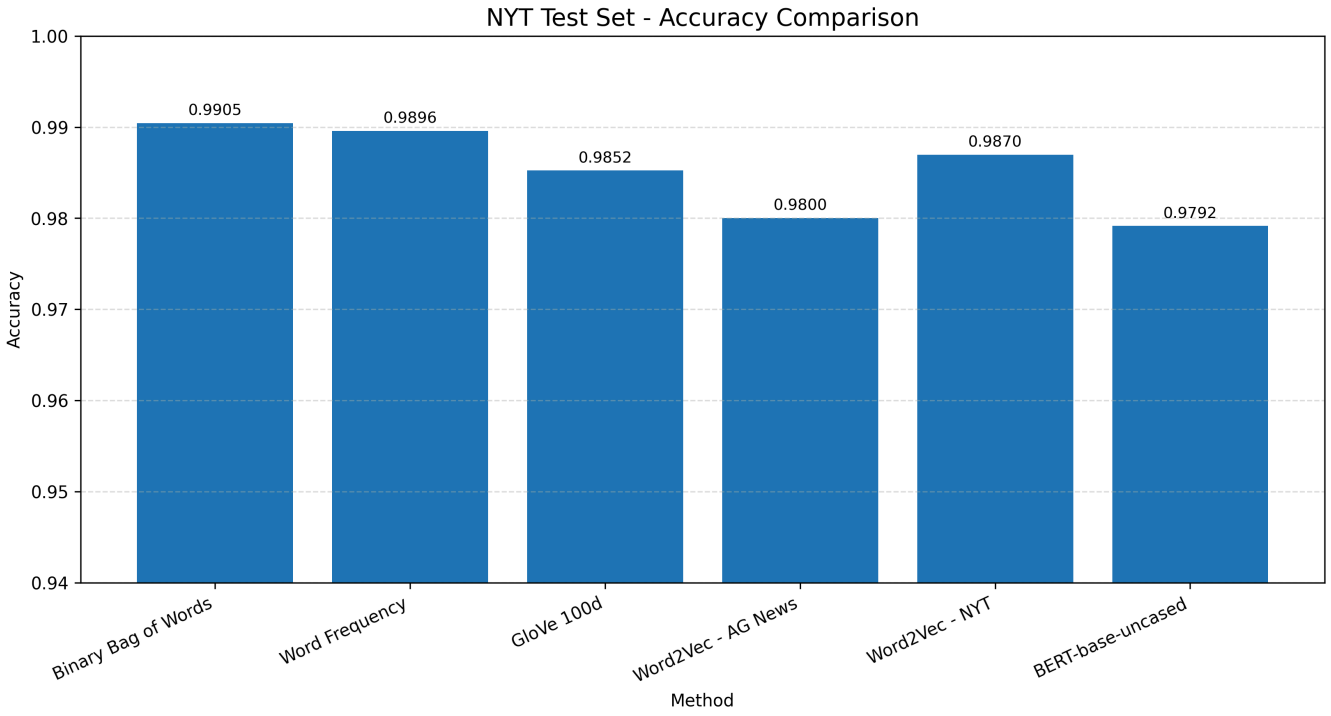
Method	Test Accuracy	Test Macro-F1
Binary Bag of Words	0.990451	0.976383
Word Frequency	0.989583	0.974178
GloVe 100d	0.985243	0.964617
Word2Vec-AG News	0.980035	0.950803
Word2Vec-NYT	0.986979	0.967214
BERT-base-uncased	0.979167	0.951085



从结果可以看出，Binary Bag of Words 同时获得最高的 Test Accuracy 和 Test Macro-F1，分别为 0.990451 和 0.976383。Word Frequency 排名第二，Word2Vec-NYT 排名第三，说明传统文本表示方法在本次新闻分类任务中取得了较好的效果。

7.2 Accuracy 对比分析

为更加直观地展示不同模型的分类效果，使用 Matplotlib 绘制六种方法在 NYT Test Set 上的 Accuracy 柱状图。

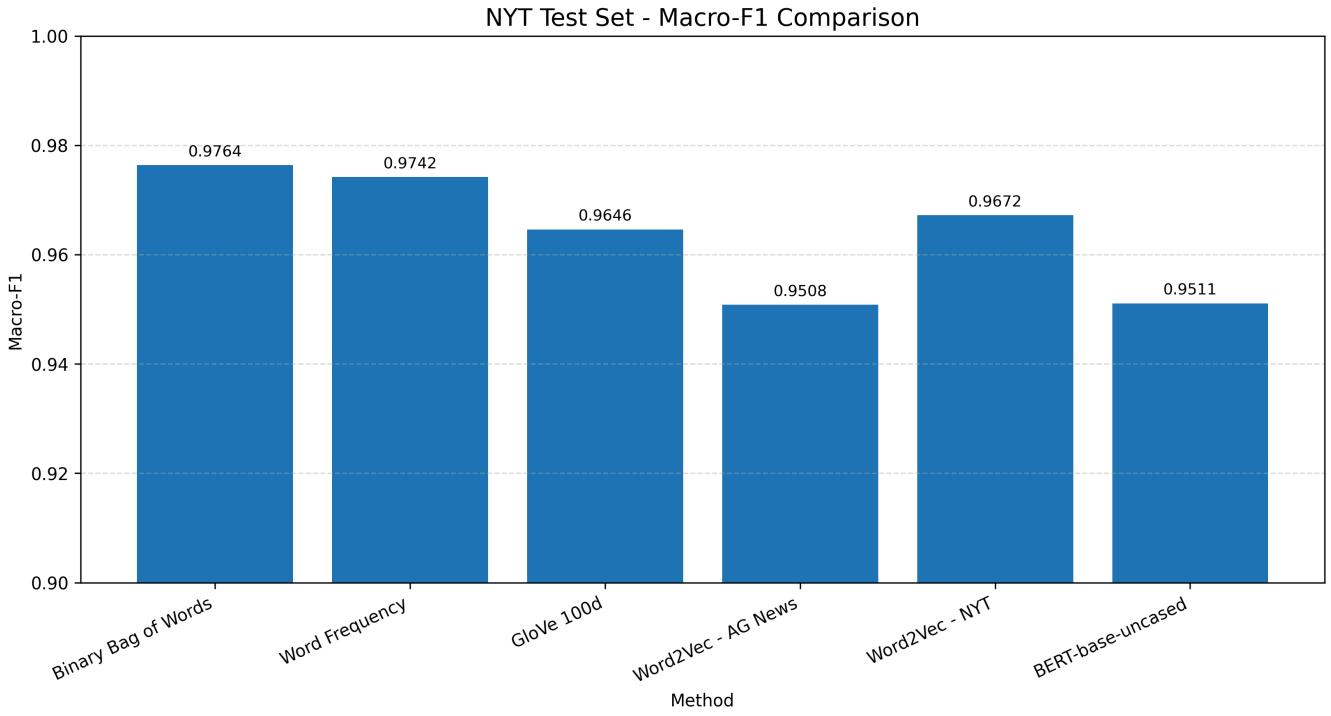


从图中可以看出，六种方法的 Accuracy 均超过 97%。其中 Binary Bag of Words 的 Accuracy 最高，为 99.0451%；Word Frequency 为 98.9583%；Word2Vec-NYT 为 98.6979%。BERT-base-uncased 的 Accuracy 为 97.9167%，在本次实验中排名第六。

这一结果说明，对于当前 NYT 新闻分类数据集，简单的词袋特征配合 Logistic Regression 已经能够取得较好的分类效果。

7.3 Macro-F1 对比分析

由于 NYT 数据集存在类别不平衡现象，仅使用 Accuracy 不能完全反映模型在不同类别上的分类能力，因此进一步比较各模型的 Macro-F1。



从 Macro-F1 对比结果可以看出，Binary Bag of Words 仍然排名第一，Macro-F1 为 0.976383。Word Frequency 和 Word2Vec-NYT 分别为 0.974178 和 0.967214。BERT-base-uncased 的 Macro-F1 为 0.951085，略高于 Word2Vec-AG News 的 0.950803。

因此，BERT 虽然在 Accuracy 指标上排名最后，但在 Macro-F1 指标上并非最低。

7.4 模型性能综合分析

根据六种文本分类方法在 NYT Test Set 上的实验结果，结合 Accuracy 和 Macro-F1 两项评价指标，可以得到以下结论：

首先，Bag of Words 方法在本次实验中表现最好。Binary Bag of Words 和 Word Frequency 在两项指标中分别排名第一和第二，说明对于新闻文本分类任务，具有较强类别区分能力的关键词能够有效支持分类。相比其他方法，传统词袋模型结构简单，但仍能取得较好的分类效果。

其次，Word Embedding 方法能够通过低维词向量表示文本，其中 Word2Vec-NYT 在两项指标中均排名第三，优于 GloVe 和 Word2Vec-AG News。这说明在本次实验中，使用目标任务数据训练词向量能够获得较好的分类效果，训练语料与目标数据之间的相关性可能对模型性能产生一定影响。

最后，BERT-base-uncased 虽然具有较强的上下文建模能力，但在本次实验中并未取得最高的分类性能。这可能与最大序列长度、训练轮数、数据集规模及类别分布等因素有关，不能据此认为 BERT 在所有文本分类任务中均不如传统方法。

为进一步比较各模型的综合表现，将六种方法分别按照 Accuracy 和 Macro-F1 进行排序，结果如图所示。

```
NYT Test Set Classification Report:

              precision    recall  f1-score   support

    business     0.9384    0.9580    0.9481       143
    politics     0.9648    0.9448    0.9547       145
      sports     0.9988    0.9988    0.9988       864

    accuracy                         0.9870      1152
   macro avg     0.9673    0.9672    0.9672      1152
weighted avg     0.9870    0.9870    0.9870      1152
```

从图可以看出，两项指标的前三名均为 Binary Bag of Words、Word Frequency 和 Word2Vec-NYT，说明这三种方法在本次实验中具有较好的综合分类性能。GloVe 在两项指标中均排名第四，而 BERT-base-uncased 和 Word2Vec-AG News 的排名存在一定差异，说明不同评价指标对模型性能的反映有所不同。

综合来看，Binary Bag of Words 在本次实验中取得了最好的分类效果。实验表明，对于当前 NYT 新闻文本分类任务，传统词袋模型结合 Logistic Regression 已能够实现较高的分类准确率，而模型结构更加复杂并不一定意味着分类性能更好。

八、实验总结

本实验围绕 NYT 新闻文本分类任务，完成了 Bag of Words、Word Embedding 和 BERT 三类方法的实现与比较。

在 Task 1 中，分别使用 Binary Bag of Words 和 Word Frequency 提取文本特征，并结合 Logistic Regression 完成分类。其中 Binary Bag of Words 的效果最好，Test Accuracy 为 0.990451，Macro-F1 为 0.976383。

在 Task 2 中，使用预训练 GloVe、基于 AG News 训练的 Word2Vec 和基于 NYT 训练的 Word2Vec 生成 100 维文档向量。其中 Word2Vec-NYT 的分类效果最好，说明词向量训练语料与目标任务的匹配程度对分类效果具有一定影响。

在 Task 3 中，使用 BERT-base-uncased 进行 3 个 Epoch 的 Fine-tuning，并完成 NYT Test Set 分类评价，最终 Accuracy 为 0.979167，Macro-F1 为 0.951085。

综合六种方法的实验结果，Binary Bag of Words 在本实验中取得最佳分类性能。

通过本次实验，掌握了新闻文本数据预处理、词袋特征构建、词向量训练、文档向量生成、Logistic Regression 分类以及 BERT Fine-tuning 的基本流程，并进一步理解了不同文本表示方法在分类性能方面的差异。